Napredni algoritmi i strukture podataka

Otkaz i oporavak, Sekvencijalno i nasumično čitanje i pisanje

Strukture zasnovane na log-u, Write Ahead Log

Univerzitet u Novom Sadu
Fakultet Tehničkih Nauka

Otkaz i oporavak

- Mreža je vrlo nepouzdana
- Čvorovi otkazuju nezavisno jedan od drugog
- Njihovi diskovi ne moraju nužno da otkažu
- To možemo da iskoristimo da rekonstruišemo stanje sistema, u slučaju otkaza
- Cilj nam je da postignemo mogućnost povratka stanja sistema, nakon otkaza, tj. nakon ponovnog pokretanja sistema

Kako to da postignemo, ideje :) ?

Sekvencijalno i nasumično čitanje i pisanje

- Ulazno izlazne operacije (I/O) na računaru, nisu stvorene jednake!
- Ovde se pod I/O operacijama misli na operacije koje se izvode nad diskom računara
- Da bismo razumeli razliku u performansama I/O operacija, zamislite kancelariju veterinara
- Svi podaci se skladište na papiru u ormarićima za datoteke
- Za jednu životinju, sve informacije se čuvaju u različitim fasciklama
- Fascikle su smeštene u različite ormare prema nekim kategorijama

Pitanje

- Koliko je jednostavno pronaći potrebne informacije?
- Da li bi bilo lakše da se svi podaci nalaze u jednoj datoteci, tako da možemo da ih preuzmemo u jednom koraku?

- Ovo je u osnovi razlika dva pristupa: **(1)** nasumičnog (random) I/O-a i **(2)** sekvencijalnog I/O-a
- Nasumično pristupanje podacima je mnogo sporije i manje efikasno od sekvencijalnog (uzastopnog) pristupa
- Pogotovo kada su u ugri velike količine podataka
- Jednostavno gledano, brže je pisati/čitati iste podatke sa jednim uzastopnim I/O, nego više manjih nasumičnih I/O operacija
- Za ovo postoje jednostavne strukture podataka na koje se možemo osloniti
- Ovo naravno ne znači da treba izbegavati nasumični pristup!!
- Treba razmisliti o radu sistema, i pristupu podacima – identifikovati potrebe!

Strukture zasnovane na log-u

- Osnovna organizacija podataka je *log* (dnevnik) — niz *append-only* zapisa
- Ideja je nastala 1980ih kao *Log Structured File System*, danas se ova ideja dosta koristi kod baza podataka i sistema koji rade sa velikim količinama podataka
- Zapisi u *log-u* su nepromenljivi, i dodaju se u strogo u sekvencijalnom redosledu **na kraj datoteke**
- *Log* je struktura podataka sa konstantnom $\mathcal{O}(1)$ brzinom pisanja/čitanja
- *Log* je efikasan na HDD i SSD diskovima
- Brzina se ne smanjuje čak i ako dnevnik ima terabajte podataka
- Uzmite to u obzir jer su u *cloud-u* HDD-ovi mnogo jeftiniji od SSD-ova

- Čitanje $\mathcal{O}(1)$
- Pisanje $\mathcal{O}(1)$
- Pretraga $\mathcal{O}(n)$ — full scan

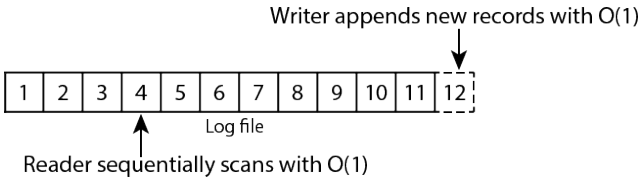

(Log data structure, https://scaling.dev/storage/log)

Dodatni materijali

- Log data structure
- Log Structured File System for Dummies (nije uvredljivo :))
- Log Data Structure USENIX

Strukture zasnovane na log-u - Pitanja

Pitanja :) ?

Problem

Od vas se zahteva da implementirate sistem za skladištenje podatka (u npr. Facebook-u), i pred vama su sledeći zahtevi:

- Snažna garancija trajnosti podataka je potrebna, čak i u slučaju da mašine otkažu
- Kada mašina pristane da izvrši operaciju, trebalo bi da to uradi čak i ako ne uspe ili se restartuje gubeći prethodno stanje u memoriji

Predlozi :) ?

Write Ahead Log - Ideja

- Kada se zapis upiše u neko skladište podataka, on se čuva na dva mesta: **(1)** Memorijska struktura (više o tome kasnije) i **(2)** Write Ahead Log (WAL).
- WAL deluje kao rezervna kopija na disku, za memorijsku strukturu tako što vodi evidenciju o svim operacijama nad skladištem podataka
- U slučaju ponovnog pokretanja sistema (restart), memoriska struktura se može u potpunosti oporaviti (rekonstruisati) ponavljanjem operacija iz WAL-a
- Kada memorijska strukutra dostigne definisani kapacitet transformiše se u strukturu na disku (više o tome kasnije), WAL se briše sa diska da bi se napravio prostor za novi WAL
- Vrlo jednostavna, vrlo moćna ideja – *Occam's razor*

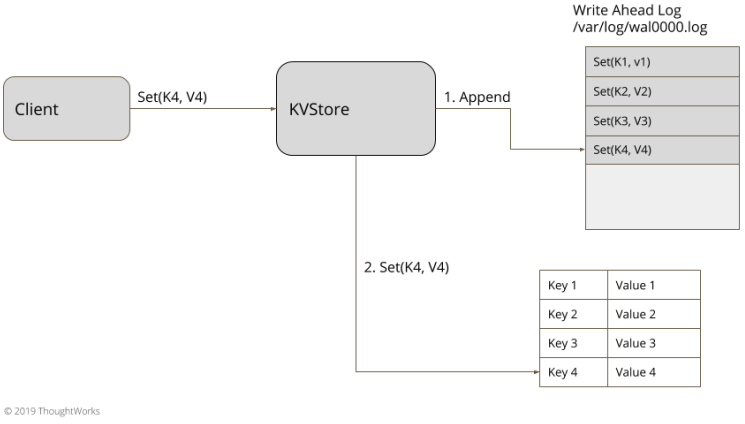

(Martin Fowler Write-Ahead Log https://martinfowler.com/articles/patterns-of-distributed-systems/wal.html)

Write Ahead Log - Osobine

- Sekvencijalni I/O je brži od nasumičnih I/O operacija
- Sistem kao što su npr baze podataka treba da odgovare ovoj realnosti
- WAL koristi isključivo sekvencijalni I/O za skladištenje podataka na disku
- WAL kao struktura podatka, direktno se oslanja na strukturu zasnovanu na log-u
- Prosto gledano, WAL je jedan veliki log na disku
- ALI, i dodaje neke svoje specifi cnosti, da bi odgovorio raznim problemima
- Prilično moćan i široko korišćen mehanizam u modernom softveru

Write Ahead Log - Osobine

- Ovaj pristup ima i svoje nedostatke — *Nema besplatnog ručka!*
- WAL plaća svoju poboljšanu brzinu pisanja, dodatnim prostorom na disku
- Svaki put kada se zapis ažurira, stare verzije zapisa se čuvaju i zauzimaju dodatan prostor na disku – *nepromenljivost podataka*
- Ovim postižemo da se podaci neće menjati, i u slučaju otkaza, možemo da reskonstruišemo zapise kako su se oni dešavali, ali zauzimamo dodatne resurse za te operacije
- ALI dobrovoljno se odričemo tih resursa zarad, benefiti koje nam ta žrtva donosi

Write Ahead Log - Space Amplification

- Odluka da se stare verzije čuvaju, u teoriji dizajna baze podataka je poznato kao *Space Amplification*
- Space Amplification je umnožak koliko prostora za skladištenje se koristi za datu veličinu skupa podataka
- Na primer, skup podataka od 1 GB sa faktorom amplifikacije od *2x* bi rezultirao korišćenjem diska od 2 GB.
- Iako nije važno za vaš projekat, to je nešto o čemu su dizajneri baza podataka svesni i to se optimizuje
- Ove stvari se proračuvanavaju unapred!

Write Ahead Log - Buffered i Unbuffered I/O

- Ovo je jedna od velikih tema za debatu u dizajnu baze podataka — baferovan nasuprot nebaferovan I/O
- Danas aplikacije zahtevaju više od baza podataka, dok diskovi ne drže korak sa ovim zahtevima
- Da bi se diskovi učinili bržim, OS mapira delove diska u memoriju (tema za sledeći put)
- Ovaj mehanizam amortizuje razlike u brzinama diskova i memorije

- Promene na disku se dešavaju samo u memoriji, a periodično OS upisuje promene na fizički disk
- Ovo je poznato kao baferovani I/O — zapisujemo podatke u bafer koji se na kraju isprazni na disk – kada se za to stvore uslovi
- Baferovani I/O se može izbeći korišćenjem I/O bez baferovanja — podatke upisujemo direktno na fizički disk odmah kako dolaze
- Ovo može rezultovati **prevelikim brojem operacija ka disku**
- Dodatno usporava sistem, **ALI** daje stroge garancije trajnosti podataka
- Opet imamo dva ekstrema – uzeti najbolje od dva sveta

Write Ahead Log - Struktura

Struktura može da se razlikuje od sistema do sistema, ali neka okvirna struktura bi sadržala sledeće elemente:

- Identifikator zapisa — id
- Niz bajtova koji reprezentuje podatke koji se zapisuju
- Informaciju da li je podatak dodat, ili obrisan (*Tombstone*) – nema izmene niti brisanja sadržaja
- Vremensku odrednicu kada je zapis načinjen

Struktura može da se razlikuje, primer je RockDB, popularan engine za NoSQL engine:

```
+----------+-----------+-----------+----------------+--- ... ---+
| CRC (4B) | Size (2B) | Type (1B) | Log number (4B)| Payload   |
+----------+-----------+-----------+----------------+--- ... ---+
CRC = 32bit hash computed over the payload using CRC
Size = Length of the payload data
Type = Type of record
       (kZeroType, kFullType, kFirstType, kLastType, kMiddleType )
       The type is used to group a bunch of records together to represent
       blocks that are larger than kBlockSize
Payload = Byte stream as long as specified by the payload size
Log number = 32bit log file number, so that we can distinguish between
records written by the most recent log writer vs a previous one.
```

(RocksDB Write-Ahead-Log-File-Format

https://github.com/facebook/rocksdb/wiki/Write-Ahead-Log-File-Format)

Format koji ćemo mi koristiti biće sličan RocksDB-u, ali malo uprošćen

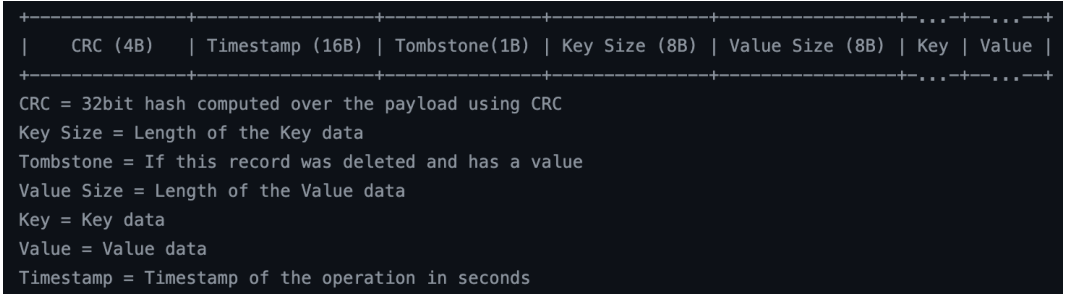

*Podaci se čuvaju u binarnom obliku. Za čitanje, potrebno je ispravno prolaziti kroz binarni fajl i čitati podatke sa njihovih pozicija

Dodatni materijali

- Write-Ahead Log for Dummies (nije uvreda :))
- Write Ahead Log Martin Fowler
- Database Internals: A Deep Dive into How Distributed Data Systems Work
- Read, write and space amplification
- ARIES/NT: A Recovery Method Based on Write-Ahead Logging for Nested Transactions

Write Ahead Log - Pitanja

Pitanja :) ?