Napredni algoritmi i strukture podataka

Rad sa fajlovima, serijalizacija

Univerzitet u Novom Sadu
Fakultet Tehničkih Nauka

Vrste fajlova

- Fajl predstavlja kolekciju podataka trajno uskladištenih na disku pod određenim nazivom
- Sadržaj svakog fajla je niz nula i jedinica, a način njihove interpretacije je ono što razlikuje različite formate datoteka
- Osnovna podela datoteka jeste na binarne i tekstualne
- Tekstualni fajlovi sačinjeni su iz niza karaktera transformisanih u nizove bitova prema određenom enkodingu (UTF-8, UTF-16, ASCII ...)
- Za binarne fajlove ovo pravilo ne važi i za svaki format se definiše koji tip sadržaja čuva i na koji način se taj sadržaj zapisuje i interpretira

Permisije nad fajlovima

- Većina fajl sistema svakom fajlu dodeljuje atribute koji definišu koji korisnik sme da vrši koje akcije nad tim fajlom
- Unix sistemi razlikuju tri akcije odnosno dozvole - čitanje, pisanje i izvršavanje
- Dozvole se dodeljuju odvojeno za tri klase - vlasnika, grupu i ostale korisnike

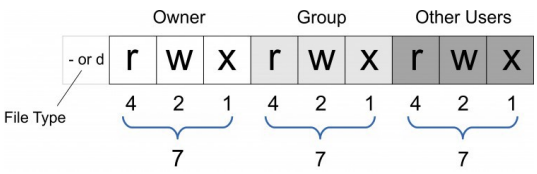

Kreiranje

- Novi fajl može biti kreiran pomoću funkcije Create() paketa os
- Jedini parametar funkcije je naziv fajla, navodi se relativna ili apsolutna putanja do odredišnog direktorijuma, a zatim i sam naziv fajla
- Funkcija vraća pokazivač na novokreirani fajl i grešku

```
file, err := os.Create("somefile")
if err != nil {
      panic(err)
}
```

Brisanje

- Brisanje postojećeg fajla obavlja se funkcijom Remove() paketa os
- Jedini parametar funkcije je naziv fajla, navodi se relativna ili apsolutna putanja do odredišnog direktorijuma, a zatim i sam naziv fajla
- Funkcija vraća samo grešku do koje je potencijalno došlo

```
err := os.Remove("somefile")
if err != nil {
      panic(err)
}
```

Dobavljanje informacija

- Informacije o fajlu kao što su njegov naziv, veličina u bajtima, kada je poslednji put izmenjen, da li je direktorijum itd. mogu se dobaviti upotrebom funkcije Stat() paketa os

```
fileInfo, err := os.Stat("somefile")
if err != nil {
      panic(err)
}
fmt.Println("File name:", fileInfo.Name())
fmt.Println("Size in bytes:", fileInfo.Size())
fmt.Println("Is Directory: ", fileInfo.IsDir())
```

- Na sledeći način proveravamo da li fajl postoji

```
if _, err := os.Stat(fileName); err != nil {
      if os.IsNotExist(err) {
        return false
      }
}
```

Izmena naziva i premeštanje

- Fajl može biti preimenovan (premešten izmenom putanje) pomoću funkcije Rename() paketa os
- Prvi parametar je stara, a drugi nova putanja do fajla
- Funkcija vraća samo grešku do koje je potencijalno došlo

```
err := os.Rename("somefile", "somefile2")
if err != nil {
      panic(err)
}
```

Otvaranje i zatvaranje

- Funkcija os.Open() otvara fajl (ukoliko on postoji) u read-only režimu i vraća pokazivač na otvoreni fajl i grešku
- Zatvaranje fajla vrši se pozivom metode Close() nad pokazivačem na fajl

```
file, err := os.Open(fileName)
. . .
file.Close()
```

- Kada želimo da menjamo sadržaj fajla, moramo koristiti funkciju os.OpenFile()
- Prvi parametar funkcije je naziv fajla, nakon čega sledi flag koji naznačava u kom režimu se fajl otvara, posle čega se navode dozvole
- Moguće vrednosti flag-a su **O_RDONLY**, **O_WRONLY**, **O_RDWR**, **O_APPEND**, **O_CREATE**, O_EXCL, O_SYNC, O_TRUNC
- Može se navesti više od jednog flag-a, između kojh se navodi OR (|) operator

```
file, err = os.OpenFile("somefile", os.O_RDWR | os.O_CREATE, 0666)
```

Kopiranje

- Kopiranje sadržaja fajla vrši se tako što se otvori postojeći i kreira novi fajl, a zatim pozove funkcija os.Copy() koja kao parametre prima pokazivač na novi fajl i pokazivač na postojeći fajl
- Povratnu vrednost čine broj kopiranih bajtova i greška
- Nakon toga potrebno je pozvati metodu Sync() nad novim fajlom kako bi izmene bile zapisane na disk

```
bytesWritten, err := io.Copy(newFile, originalFile)
. . .
err = newFile.Sync()
```

Pozicioniranje

- Pozicioniranje na tačno određeno mesto (bajt) u fajlu pred naredno čitanje ili pisanje vrši se metodom Seek() koja se poziva nad fajlom
- Prvi parametar funkcije je offset (za koliko bajtova se vrši pomeranje), dok je drugi parametar flag koji određuje u odnosu na šta se vrši pomeranje
- Moguće vrednosti flag-a:
  - 0 - U odnosu na početak fajla
  - 1 - U odnosu na trenutnu poziciju
  - 2 - U odnosu na kraj fajla

```
// pomeramo se na peti bajt u odnosu na početak fajla
newPosition, err := file.Seek(5, 0)
```

Pisanje I

- Jedan od načina za zapisivanje sadržaja u fajl je pomoću Write() metode pokazivača na fajl
- Jedini parametar funkcije je niz bajtova koje treba zapisati
- Povratne vrednosti su broj zapisanih bajtova i greška

```
file, err := os.OpenFile(fileName, os.O_WRONLY, 0666)
if err != nil {
      log.Fatal(err)
}
defer file.Close()
byteSlice := []byte("Bytes!\n")
bytesWritten, err := file.Write(byteSlice)
if err != nil {
      log.Fatal(err)
}
```

Pisanje II

- Drugi način oslanja se na paket io/ioutil i njegovu metodu WriteFile() koja je pogodna za brzo upisivanje sadržaja u fajl kada on nije preveliki
- Prvi parametar funkcije je naziv fajla, nakon čega se navodi niz bajtova koje treba upisati, dok je poslednji parametar rezervisan za navođenje permisija koje će biti dodeljene fajlu u slučaju da on ranije nije postojao

```
err := ioutil.WriteFile(fileName, []byte("Hi\n"), 0666)
if err != nil {
      log.Fatal(err)
}
```

Pisanje III

- Treći način zapisa koristi bufio paket koji nudi mogućnost baferisanog zapisivanja u promenljive čiji tip implementira io.Writer interfejs
- Bafer ima maksimalnu veličinu, predefinisana vrednost je 4096 bajtova, a može se i menjati
- Sadržaj se dodaje u bafer metodom Write()
- Metodom FLush() sadržaj se zapisuje na disk u slučaju fajla, a bafer se nakon toga prazni
- Sadržaj bafera se može obrisati pozivom metode Reset()
- Metode Size(), Buffered() i Available() pružaju informacije o ukupnoj veličini bafera, broju popunjenih bajtova i broju slobodnih bajtova

Pisanje IV

```
bufferedWriter := bufio.NewWriter(file)
bytesWritten, err := bufferedWriter.Write(
      []byte{65, 66, 67},
)

bytesWritten, err = bufferedWriter.WriteString(
      "Buffered string\n",
)

bufferedWriter.Flush()
bufferedWriter.Reset(bufferedWriter)

bufferedWriter = bufio.NewWriterSize(
      file, 8000)
```

Čitanje I

- Pokazivač na fajl (i svaki drugi tip koji implementira interfejs io.Reader) poseduje metodu Read()
- Sadržaj se upisuje u niz bajtova koji se prosleđuje kao argument
- Poziv funkcije vraća grešku kada se na početku čitanja nalazimo na kraju fajla

```
bytes := make([]byte, 2)
_, err = file.Read(bytes)
if err != nil {
      panic(err)
}
```

Čitanje II

- Funkcija io.ReadFull() učitava sadržaj fajla koji se navodi kao prvi argument u niz koji se navodi kao drugi argument
- Ukoliko je sadržaj koji se čita kraći od zadatog niza, poziv funkcije će vratiti grešku

```
bytes := make([]byte, 2)
_, err = io.ReadFull(file, bytes)
if err != nil {
      panic(err)
}
```

- Funkcija io.ReadAtLeast() učitava najmanje n bajtova gde je n zadato i vraća grešku ukoliko ne može da pronađe barem toliko bajtova

```
bytes := make([]byte, 2)
_, err = io.ReadAtLeast(file, bytes, 1)
if err != nil {
      panic(err)
}
```

Čitanje III

- Svi prethodni načini učitavaju sadržaj u niz čija je dužina zadata pre samog čitanja
- Funkcija ioutil.ReadAll() učitava ceo fajl i kao povratnu vrednost vraća niz popunjen sadržajem

```
bytes, err := ioutil.ReadAll(file)
if err != nil {
      panic(err)
}
```

- Još jedan način za učitavanje sadržaja celog fajla je uz pomoću ioutil.ReadFile() funkcije
- Razlika je ta da se u ovom slučaju navodi putanja fajla, a ne pokazivač na fajl

```
bytes, err := ioutil.ReadFile("folder/somefile")
if err != nil {
      panic(err)
}
```

Čitanje IV

- U situacijama zahtevnijim za obradu pogodno je koristiti bufio paket kao i pri pisanju u fajl
- Metoda Peek() vraća narednih n bajtova u odnosu na trenutnu poziciju, tako da trenutna pozicija nakon poziva ostaje ista

```
bufferedReader := bufio.NewReader(file)
byteSlice := make([]byte, 5)
byteSlice, err = bufferedReader.Peek(5)
```

- Metoda Read() takođe vraća narednih n bajtova, ali tako da se nakon poziva trenutna pozicija menja

```
numBytesRead, err := bufferedReader.Read(byteSlice)
```

Čitanje V

- Pozivom metode ReadByte() čita se naredni bajt, ukoliko postoji, ili se vraća greška ukoliko ne postoji

```
myByte, err := bufferedReader.ReadByte()
```

- ReadBytes() i ReadString() metode kao parametar uzimaju vrednost delimitera i vraćaju sadržaj fajla do zadatog delimitera (zajedno sa njim)

```
dataBytes, err := bufferedReader.ReadBytes('\n')
dataString, err := bufferedReader.ReadString('\n')
```

Čitanje VI

- Za obradu tekstualnog sadržaja pogodno je koristiti strukturu Scanner iz bufio paketa koja obrađuje fajl token po token
- Podrazumevano ponašanje skenera je da učitava liniju po liniju teksta pozivom metode Scan()
- Kao funkcija za podelu tokena može se registrovati bilo koja funkcija SplitFunc tipa (postojeće su ScanWords i ScanRunes)

```
scanner := bufio.NewScanner(file)
scanner.Split(bufio.ScanWords)
success := scanner.Scan()
if success == false {
      err = scanner.Err()
      if err == nil {
        log.Println("Scan completed and reached EOF")
      } else {
        log.Fatal(err)
      }
}
fmt.Println("First word found:", scanner.Text())
```

Pojam serijalizacije

- Serijalizacija predstavlja postupak prevođenja stanja objekta u niz bajtova sa ciljem njihovog trajnog skladištenja ili prenosa preko mreže
- To stanje kasnije može rekonstruisati procesom deserijalizacije, čestoi u drugačijem okruženju
- Formati za serijalizaciju su brojni i mogu se podeliti na tekstualne (JSON, XML, CSV, YAML) i binarne (BSON, MessagePack, protobuf)

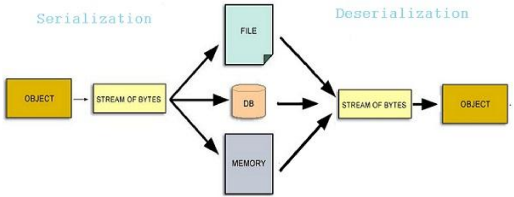

encoding/binary paket

- Paket encoding/binary implementira jednostavnu translaciju između brojeva i niza bajtova
- Translacija se vrši čitanjem i pisanjem vrednosti fiksne dužine
- Vrednost fiksne dužine ili imaju tip fiksne dužine (bool, int8, int16, uint8, float32, complex64 ...) ili predstavljaju niz ili strukturu koja sadrži samo vrednosti fiksne dužine
- Predstavlja pogodan način za kodiranje struktura podataka sa numeričkim vrednostima u njihovu binarnu reprezentaciju
- Može predstavljati i osnovu za kreiranje sopstvenih binarnih formata i protokola

ByteOrder I

- Redosled bajtova diktira na koji će način biti kodirane vrednosti dužine veće od jednog bajta
- Implementacije ByteOrder interfejsa su LittleEndian i BigEndian
- Treba voditi računa da se prilikom serijalizacije i deserijalizacije koristi ista implementacija kako bi se očuvala semantika podatka

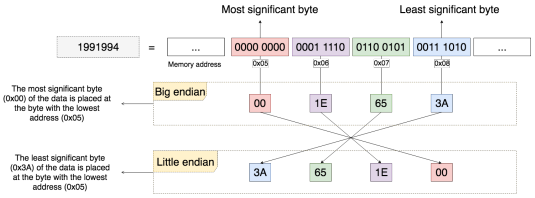

ByteOrder II

```
b := []byte{1, 2, 3, 4}
val := binary.LittleEndian.Uint32(b)
fmt.Printf("Little endian: %b\n", val)
//output: Little endian: 00000100000000110000001000000001
val2 := binary.BigEndian.Uint32(b)
fmt.Printf("Big endian: %b\n", val2)
//output: Big endian: 00000001000000100000001100000100
binary.LittleEndian.PutUint32(b, val2)
fmt.Println(b)
//output: [4 3 2 1]
```

Serijalizacija struktura

- Paket poseduje funkcije Read i Write kojima se iz io.Reader-a čita ili u io.Writer piše određeni podatak, uz navođenje odgovarajućeg ByteOrder-a

```
vertex := Vertex{3, 2}
err = binary.Write(file, binary.LittleEndian, vertex)
if err != nil {
      panic(err.Error())
}
file.Seek(0, 0)
newv := &Vertex{}
err = binary.Read(file, binary.LittleEndian, newv)
if err != nil {
      panic(err.Error())
}
fmt.Println(*newv)
//output: {3 2}
```

encoding/gob paket I

- Paket gob deo je standardne Go biblioteke i služi za serijalizaciju i deserijalizaciju kompleksnih struktura podataka
- Nedostatak ovog formata je u tome što trenutno postoji implementacija samo u Go-u
- Transformacija podataka obavlja se pomoću struktura Encoder i Decoder
- Encoder poseduje metodu Encode() kojoj se kao argument prosleđuje bilo šta (što nije funkcija ili kanal) i ta vrednost se serijalizuje u niz bajtova
- Taj niz bajtova biće zapisan u promenljivu čiji tip implementira io.Writer interfejs, a koja se navodi pri kreiranju enkodera

```
student := Student{"Pera Peric",22}
file, err := os.OpenFile("./student.gob", os.O_RDWR | os.O_CREATE, 0666)
encoder := gob.NewEncoder(file)
err = encoder.Encode(student)
```

encoding/gob paket II

- Dekoder obavlja dekodiranje pomoću metode Decode() kojoj se prosleđuje promenljiva u koju će rezultat biti upisan
- Mora biti prosleđen pokazivač na željeni tip

```
decoder := gob.NewDecoder(file)
var studentRead = new(Student)
file.Seek(0, 0)
for {
      err = decoder.Decode(studentRead)
      if err != nil {
        break
      }
      fmt.Println(*studentRead)
}
```

encoding/gob paket III

- Prilikom serijalizacije, u obzir se uzimaju samo eksportovana polja strukture, dok se neeksportovana zanemaruju
- Takvo ponašanje moguće je promeniti ako struktura implementira GobEncoder i GobDecoder interfejse i njihove metode GobEncode() i GobDecode()

```
type GobEncoder interface {
      // GobEncode returns a byte slice representing the encoding of the
      // receiver for transmission to a GobDecoder, usually of the same
      // concrete type.
      GobEncode() ([]byte, error)
}
type GobDecoder interface {
      // GobDecode overwrites the receiver, which must be a pointer,
      // with the value represented by the byte slice, which was written
      // by GobEncode, usually for the same concrete type.
      GobDecode([]byte) error
}
```

Zadaci I

- Napisati funkciju koja za fajl sa zadatim nazivom ispisuje njegovu veličinui kada je poslednji put izmenjen. Ukoliko fajl ne postoji, treba ga kreirati u okviru funkcije.
- Napisati funkciju koja:
  - Kreira fajl na zadatoj putanji
  - U njega upisuje tekst "Hello from the file!"
  - Kopira njegov sadržaj u novi fajl sa nazivom "copy.txt"
  - Briše originalni fajl
- Napisati funkciju koja čita i na konzoli ispisuje prve tri reči iz "copy.txt" fajla.
- Napisati funkciju koja iz "copy.txt" fajla čita vrednost m-tog i n-tog bajta (parametri funkcije) i njihov zbir ispisuje na konzoli.
- Napisati funkciju koja se pozicionira na sredinu "copy.txt" fajla i naredna četiri bajta menja vrednostima [10, 21, 103, 15].
- Napisati funkciju koja svaki treći bajt u "copy.txt" fajlu menja vrednošću 0.

Zadaci II

- Kreirati strukturu Triangle sa poljima Edge1, Edge2 i Edge3 tako da je svako polje tipa float32. Upotrebom encoding/binary paketa:
  - Serijalizovati nekoliko vrednost tipa Triangle u fajl pod nazivom "triangles.bin"
  - Deserijalizovati drugi upisani trougao i ispisati vrednosti njegovih stranica na konzoli
  - Izmeniti taj trougao tako da mu sve stranice postanu duplo veće, a zatim te vrednosti izmeniti i u fajlu
  - Pomoću Read funkcije u slice triangles učitati poslednja dva trougla iz fajla
- Kreirati strukturu Sport sa poljima Name (string), IsTeam(boolean) i MatchDuration (int16). Upotrebom encoding/gob paketa:
  - Serijalizovati niz sa nekoliko vrednosti tipa Sport u fajl pod nazivom "sports.gob"
  - Serijalizovati jednu po jednu vrednost iz niza u fajl pod nazivom "sports2.gob"
  - Pokušati dekodiranje samo prvog studenta iz fajla "sports.gob"
  - Pokušati dekodiranje samo prvog studenta iz fajla "sports2.gob"
  - Pravilno dekodirati sve vrednosti i iz fajla "sports.gob" i fajla "sports2.gob" i ispisati ih na konzoli